



Современные архитектуры ИС



Лекция 8
Смесь экспертов (MoE)



План лекции

1. Смесь экспертов
2. Экспертный параллелизм

Роль FFN

Механизм внимания позволяет выявить зависимости между токенами

Это помогает модели понять контекст

Роль FFN

Механизм внимания позволяет выявить зависимости между токенами

Это помогает модели понять контекст

Но для корректной генерации следующего токена одного только контекста недостаточно

Роль FFN

Механизм внимания позволяет выявить зависимости между токенами

Это помогает модели понять контекст

Но для корректной генерации следующего токена одного только контекста недостаточно

Модель должна сопоставлять токены со своими знаниями о мире и тем самым извлекать информацию, заложенную в ее веса

FFN как база знаний о мире

В FFN входной токен сначала проецируется в пространство большей размерности

Каждый столбец матрицы проекции можно рассматривать как представление некоторой выученной моделью семантической концепции

Чтобы отсеять нерелевантные результаты, воспользуемся функцией активации. Например, SwiGLU

FFN как база знаний о мире

Этот результат имеет большую размерность, чем входной токен

Поэтому мы проецируем его в исходное пространство с помощью другой матрицы

В этом случае, столбцы этой матрицы выступают в роли кодировщиков полученных соответствий представлений о мире после первого слоя.

FFN как база знаний о мире

То есть, механизм внимания добавляет в каждый токен контекст остальных токенов

А FFN — это база знаний о мире, и обработка токенов блоков FFN можно трактовать как проверку соответствия токена этой базе знаний

Разреженность

То есть, если мы хотим сделать модель умнее, то нужно увеличивать количество семантических концепций, хранимых на каждом FFN-слое.

Таким образом придется увеличивать размер FFN блока и количество параметров модели

Но мы упираемся в инженерный потолок: чем больше FFN, тем больше нужно считать и тем больше данных нужно хранить в глобальной памяти

Разреженность

Однако, конкретный токен вряд ли будет соответствовать сразу всем выученным моделью концепциям.

А нерелевантные соответствия будут занулены.

Разреженность

Однако, конкретный токен вряд ли будет соответствовать сразу всем выученным моделью концепциям.

А нерелевантные соответствия будут занулены.

То есть, по сути мы проводим бесполезные вычисления

Разреженность

Однако, конкретный токен вряд ли будет соответствовать сразу всем выученным моделью концепциям.

А нерелевантные соответствия будут занулены.

То есть, по сути мы проводим бесполезные вычисления

А зачем?


Разреженность

Разобьем небольшую сеть на множество мелких сетей — **экспертов**

Так, каждый токен будет обрабатываться лишь небольшим количеством наиболее релевантных концепций в наиболее релевантных экспертах

Такой подход называется **разреженностью**


Маршрутизатор




Mixture of experts

Эксперты + маршрутизатор = MoE

Чтобы роутер обучался помощью обратного распространения, домножим выход эксперта на соответствующую вероятность из роутера




Fine-grained и общие эксперты



План лекции

1. Смесь экспертов
2. **Экспертный параллелизм**

Экспертный параллелизм



Экспертный параллелизм как часть 5D параллелизма




Fig. 8. Schematic depiction of diverse parallel strategies for MoE. For clarity and conciseness, this illustration omits some All-to-All, All-Reduce, Point-to-Point communication within parallelism, and Normalization, Encode, Decode, Gate in subfigures (b), (c), and (d).