

Силлабус курса

Современные архитектуры нейронных сетей

1. Общая информация о курсе

Название курса	Современные архитектуры нейронных сетей
Преподаватель	Прокопов Егор Максимович
Контактная информация	yemprokov@itmo.ru

2. Описание курса

Задача курса - познакомить слушателей с современными архитектурами нейронных сетей и их обучением. Будут затронуты такие темы как обучение нейронных сетей, подготовка данных, токенизация текста, архитектура трансформера и ее развитие, особенности обучения на графических процессорах NVIDIA, распределенное обучение, законы масштабирования, мультимодальность, RLHF и агенты.

3. Цели и задачи курса

- **Теоретические:** понимание современных архитектур нейронных сетей и процесса их обучения.
- **Практические:** развитие навыков работы с нейронными сетями, их обучения и оптимизации
- **Прикладные:** развитие навыков работы с PyTorch, Lightning, Triton, ClearML

4. Структура курса и темы занятий

4.1. Неделя 1-2: Введение

- **Основы.** Архитектура простейшей нейронной сети. Определение функции потерь. Прямое распространение в нейронных сетях. Алгоритм обратного распространения ошибки. Оптимизаторы (от SGD до AdamW). Bias-variance trade-off в нейронных сетях. Работа с PyTorch.
- **Transformer.** Токенизация текста. BPE-токенизатор. Архитектура Transformer. Экосистема обучения нейронных сетей: метрики, чекпоинты. ClearML.
- **Лабораторная работа 1. Работа с данными.** Очистка данных перед обучением. Реализация BPE-токенизатора.

- **Лабораторная работа 2. Реализация GPT-2** Реализация архитектуры GPT-2 с использованием PyTorch. Обучение нейронных сетей с помощью Lightning и ClearML.

4.2. Неделя 3-4: Особенности обучения на GPU

- **Обучение на одном графическом ускорителе.** Анатомия GPU, отличия GPU от CPU. Иерархия памяти. Инструменты программирования на GPU: CUDA, Triton. Инструменты профилирования. Ускорение нейронных сетей на GPU на примере FlashAttention.
- **Распределенное обучение.** Коллективные коммуникации. DDP, ZeRO, FSDP. Конвейерный параллелизм, тензорный параллелизм. Профилирование распределенного обучения.
- **Лабораторная работа 3. Triton.** Фьюз кернелов SwiGLU на Triton. Реализация FlashAttention на Triton. Реализация бенчмарков и профилирование.

4.3. Неделя 5-6: от трансформера к LLM

- **Улучшение архитектуры трансформеров.** Нормализация. Gated Linear Unit. Улучшение позиционного кодирования.
- **Эффективное внимание.** Разреженное внимание. Оконное внимание. KV-кэш. MQA, GQA и MLA.
- **Масштабирование.** Self-supervised learning. Законы масштабирования.
- **Лабораторная работа 4. Улучшение GPT-2.** Развитие и оптимизация модели из LР2 и LР3.

4.4. Неделя 7-8: большие языковые модели

- **Мультимодальность.** Смешивание модальностей. Визуальные языковые модели.
- **Удешевление работы LLM.** Смешанная точность. Квантизация. LoRA. Дистилляция.
- **Mixture of Experts.** Смысл MoE. Экспертный параллелизм. Балансировка экспертов.
- **Алайнмент LLM.** SFT. Обучение с подкреплением на основе обратной связи с человеком: PPO, GRPO, DPO. Reasoning.
- **Агенты.** Что такое агенты. Использование агентами инструментов. MCP. ReACT. Кодовые агенты.

5. Система оценивания

- Лабораторные работы: 80 баллов. Всего предусмотрено 4 лабораторные работы.
- Зачет: 20 баллов. Зачет состоит из двух вопросов (10+10 баллов).

6. Рекомендуемая литература

1. The Ultra-Scale Playbook: Training LLMs on GPU Clusters
https://huggingface.co/spaces/nanotron/ultrascale-playbook?section=high-level_overview
2. NanoGPT
<https://github.com/karpathy/nanoGPT>
3. AI Systems Performance Engineering. Optimizing Model Training and Inference Workloads with GPUs, CUDA, and PyTorch
4. The Smol Training Playbook: The Secrets to Building World-Class LLMs
<https://huggingface.co/spaces/HuggingFaceTB/smol-training-playbook>